

國立清華大學工學院學士班
113 年專題研究計畫報告書

Frequency Dependent Adaptive
SSVEP Implementation with
Arduino LED Trigger

組別：一

執行計畫學生： 賀茂騏

指導老師：莊鈞翔

中華民國 113 年 11 月 15 日

摘要

本實驗利用穩態視覺誘發電位 (SSVEP) 探討大腦對特定頻率的視覺刺激所產生的誘發反應是否因不同受試者而有差異。其目的是研究不同受試者是否對特定頻率表現出偏好，並探討這些偏好是否可以作為一種身份識別方式，類似於人臉辨識或指紋辨識等。

壹、研究動機與目的

近年來，腦機介面 (Brain Computer Interface, BCI) 裝置已能協助行動不便的患者，使其能夠藉由裝置進行動作或表達所需內容，而無需使用肢體或語言。為了更精確地分析腦波訊號，穩態視覺誘發電位 (Steady-state Visual Evoked Potentials, SSVEPs) 提供了重要的刺激訊號。和需要受試者透過思考執行動作的主動方法不同，SSVEP 的優勢在於提供不同頻率的閃爍刺激，利用大腦的共振頻率特性，將其作為訊號的接收器和放大器，並將訊號變異範圍縮小到實驗中定義的特定頻率。

在我們的研究中，通過分析 SSVEP 的腦電波 (EEG) 數據，可以觀察到受試者與不同頻率刺激產生出同步性強弱的差異。儘管實驗程序、設備、環境及分析方法完全一致，不同受試者對於不同頻率刺激的同步性表現出差異。我們甚至發現，在實驗中腦波訊號同步性存在一個 8-15Hz 範圍的上限，即使刺激頻率增加，腦波訊號仍然與較低頻率保持同步。因此，我們的實驗設計包括研究不同的分析方法以提升頻率預測的準確性，並探討最高準確率的預測頻率是否可以作為區分不同個體的識別功能。

貳、研究步驟與方法

首先，我們使用 Arduino UNO R3 開發板連接由 9 個相同顏色的 LED 組成的陣列，製作了一個簡單的閃爍頻率裝置，並將其程式設計為以 8 至 15Hz 的頻率同時閃爍。在實驗過程中，我們要求參與者佩戴由 **Artise Biomedical Co., Ltd.** 提供的 32 通道腦電圖 (EEG) 帽。這款無線 EEG 帽的優勢在於能讓參與者在實驗中自由移動。帽內使用生理鹽水作為導電介質，以降低 Ag/AgCl 電極與頭皮之間的電阻。這種阻抗的降低透過改善電導率，將電極與皮膚介面的阻抗降低至 30 μ V 以下，從而提升 EEG 訊號的質量。

實驗在一個暗室中進行。首先，參與者被要求將目光集中在 9 個 LED 陣列中心的 LED 上（如圖 1），並在準備時間後進行一個 20 秒的閉眼 Baseline Test。接著，參與者休息 5 秒後，進行 20 秒的睜眼 Baseline Test，以確保實驗結果的可靠性。在 Baseline 測試完成後，進入主實驗前會再進行一次 5 秒的休息。




圖 1

在 20 秒的刺激後，參與者進行 10 秒的休息，此時 LED 不會閃爍。這段休息時間的目的是讓參與者放鬆眼睛，避免視覺疲勞，並消除前一頻率刺激對下一組頻率的影響。這種休息與刺激的循環將按照 8 至 15Hz 頻率範圍內的每個頻率依次進行測試。在從休息階段到實驗階段及反之的過渡過程中，我們向 EEG 接收器發送標記作為事件，區分實驗的不同階段（如圖 2）。



圖 2

在數據預處理階段，首先使用 MATLAB 的 **EEGlab** 工具檢查 EEG 數據的品質，進行基本的 Preprocess，例如濾波、Re-reference 以及 Event Selection。在預處理步驟完成後，我們使用 MATLAB 的 FFT 函數將訊號從時域轉換為頻域，接著利用 Power Spectrum 檢測特定頻率是否出現對應波形，以及是否存在諧波頻率。

在確認數據品質後，原始 EEG 數據進一步透過 Python 進行預處理，應用了類似的預處理步驟。我們使用 **GitHub** 上的 **SSVEPAnalysisToolbox** 中的 Canonical Correlation Analysis, CCA 來預測該方法能產生的最高準確度。此外，我們也使用機器學習的方法，例如 Neural Network、Support Vector Machine SVM 或 Random Forest Classifier，驗證處理後數據的頻率預測準確性。最後，生成了一個熱力圖，清楚地呈現不同參與者之間的頻率預測準確性差異。整個實驗過程下來，可以得到一種適合預測原始訊號的方法，這對於未來分析個體訊號差異具有重要意義。

參、文獻回顧與探討

首先，我們檢查資料收集的品質，透過繪製 Power Spectrum 來進行檢測。例如，當 SSVEP 資料受到 8 Hz 頻率的視覺刺激時，在理想情況下，我們應該可以在功率譜中明顯觀察到 8 Hz 處的強訊號峰值，以及其諧波（如 16 Hz、24 Hz 等）也應該出現顯著的訊號增強（如圖 3 所示）。然而，當我們檢查北京清華大學的 Open Dataset 中 13.2 Hz 的資料時，可以清楚發現資料品質較差，Power Spectrum 在目標頻率及其諧波處的訊號強度表現不佳（見圖 4）。

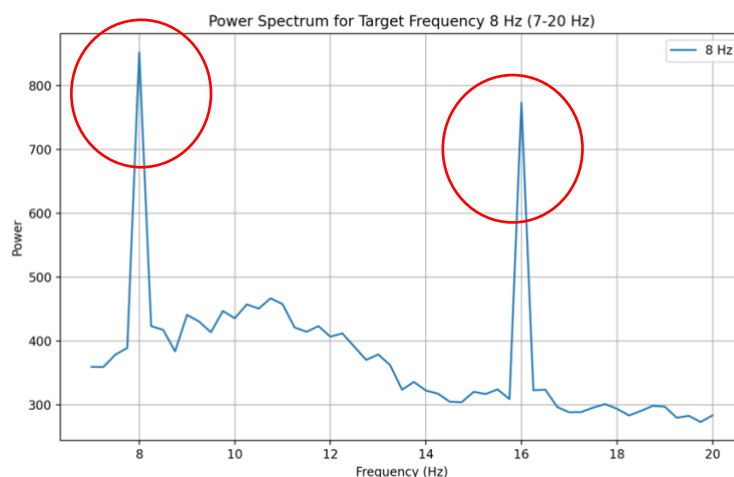


圖 3




圖 4

在檢查資料品質的同時我們也意外的發現人們對於頻率刺激的反應似乎存在著一個上限。換句話說，當閃爍頻率越高時，我們發現雖然在該頻率仍然出現出相對應的峰值，但是峰值的強度逐漸減弱。這個現象是我們在這驗證資料的過程中所發現的。(見圖 5、6、7)

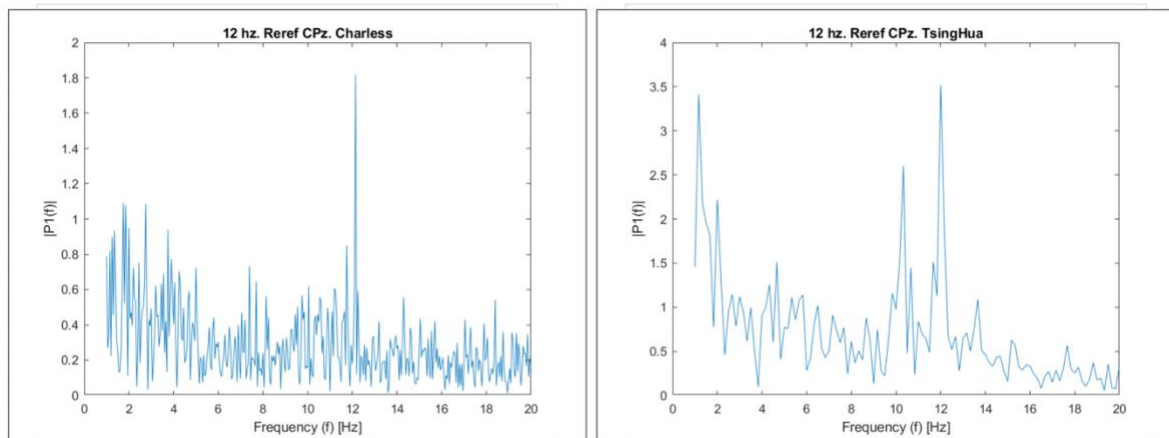


圖 5

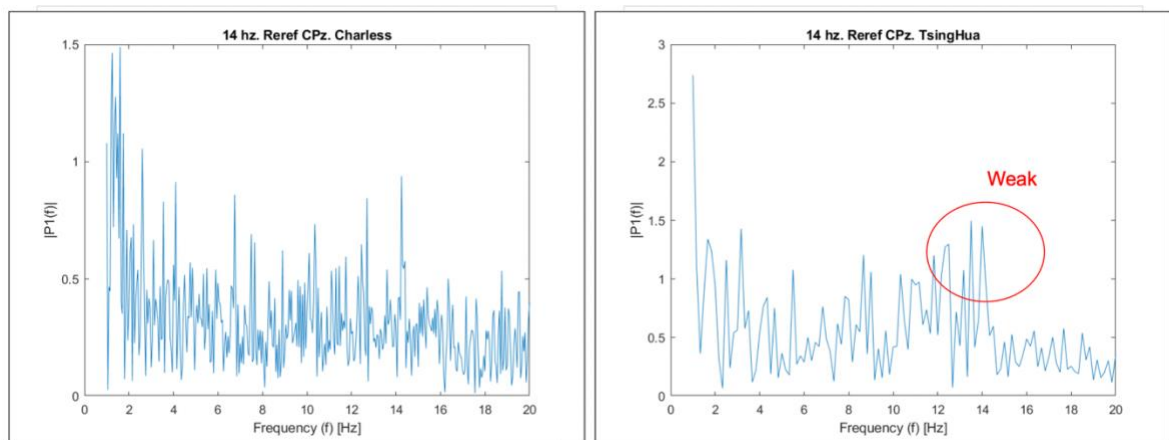


圖 6

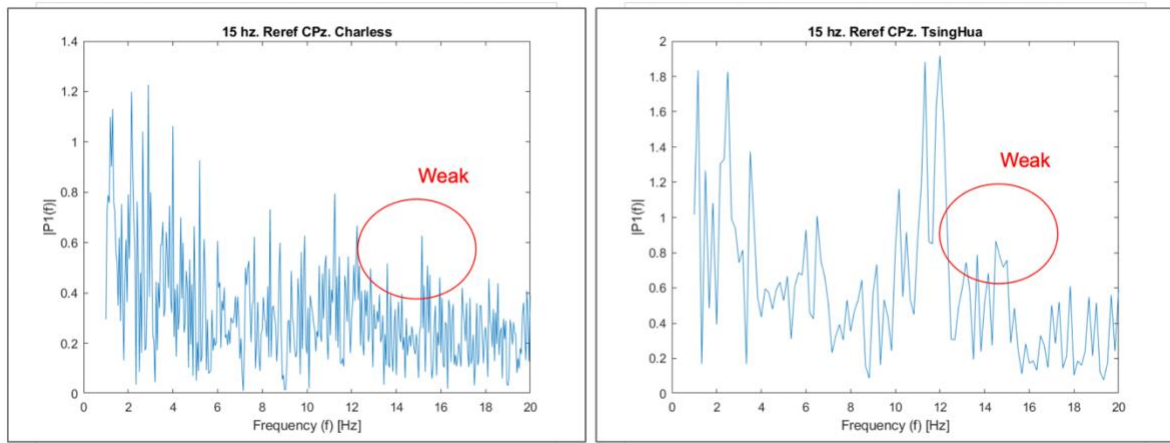


圖 7

接著，我們將這些資料導入 SSVEPAnalysisToolbox，並使用 CCA 分析方法進行處理。然而，由於我們自行收集的實驗數據量不足（僅包含三位受試者），且實驗的重複循環次數（Block 數）過少，導致預測準確率僅為 25.41%。為了增加資料集的大小，我們採用了 Sliding Window 方法。具體而言，與其直接分析整段資料，我們將其切割成較小的等分，並在這些等分之間進行部分重疊取樣。此方法有效地擴充了資料集的大小，從而提升了模型的預測準確率。此外，我們進一步觀察到，隨著 Sliding Window 的大小增加，模型準確率也相應提升。然而，這種提升趨勢呈現出類似對數曲線的特性，顯示準確率在增大到一定程度後達到上限。（如圖 8）

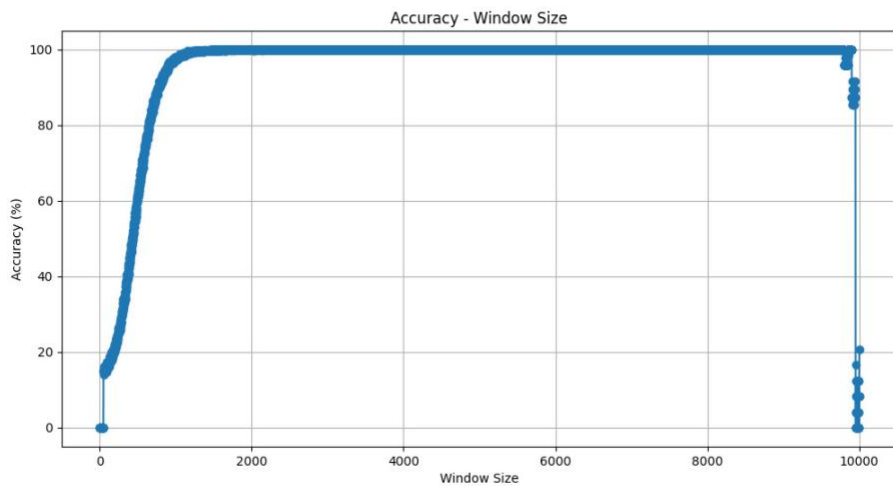



圖 8

我們嘗試使用機器學習方法，利用 Random Forest Classifier 對資料進行分類，並得到一個準確率為 70.17% 的模型（如圖 9 所示）。然而，在優化模型的過程中，我們透過 PCA 分析發現，不同頻率之間的特徵存在較高的重疊性（如圖 10 所示）。由於 Random Forest Classifier 更適合處理特徵差異明顯的分類任務，因此我們決定改用 Neural Network 方法來訓練分類模型，以期提升分類效能。



```
Final dataset shape: (848400, 159), Labels shape: (848400,)
Training set shape: (678720, 159), Test set shape: (169680, 159)
Training the Random Forest classifier...
Model training complete.
Overall Accuracy: 70.17%
```

圖 9




圖 10

使用 Neural Network 的分析方法，我們得到了準確率高達 96.23% 的分類模型 (如圖 11 所示)。因此，我們可以精確地將一筆資料輸入該模型，並獲得準確的分類結果。接著，我們根據題目要求定義了 Adaptive 的標準：選擇模型準確率最高的頻率作為偏好頻率；若兩個頻率的準確率相同，則選擇模型信心程度較高的那個頻率。




圖 11

為了驗證這一假設的正確性，我們隨機選擇了一位受試者的資料進行測試。將該資料輸入模型後，模型預測出該受試者最偏好的頻率。我們隨後利用前述的 Power Spectrum 方法，檢查該頻率下是否確實出現了較明顯的訊號峰值。以下我們以隨機選到的 Subject 4 作為驗證對象，模型預測 Subject 4 的偏好頻率為 10 Hz (如圖 13 所示)。Power Spectrum 的結果顯示，該頻率下的訊號峰值與預期一致，證實了模型的預測能力。最後，我們將所有受試者的資料輸入模型進行分析，結果顯示不同受試者對相同的 SSVEP 刺激頻率存在不同的偏好與反應程度 (如圖 12 所示)。

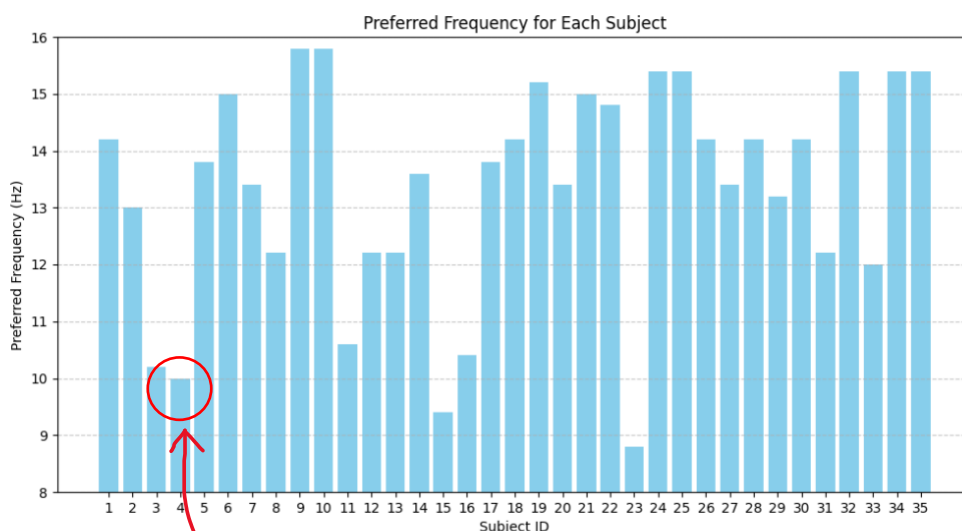


圖 12




圖 13

肆、 結論與改進方向

雖然模型能夠提供符合預期的結果，但仍然存在一些需要改進的地方。首先，由於資料集中 13.2 Hz 的數據品質普遍較差，這導致訓練出的模型在應用中可能無法廣泛通用。因此，我們認為可以考慮利用模擬資料的方式，重建 13.2 Hz 的資料集，進一步提升模型在該頻率上的表現。同時，我們也注意到目前的數據量仍然不足，品質較好的 SSVEP 開放資料集僅有北京清華所提供的資料，且受試者僅包含 35 位，限制了模型在新數據或未知情境下的適應能力。因此，未來的研究應著眼於設計一套標準化的實驗流程，並結合 Sliding Window 技術，在縮短實驗時間的同時

減少受試者的視覺疲勞，以提高數據的收集效率。增加更多受試者的參與，並進一步擴充資料集規模。

此外，模型預測的頻率是否真正代表受試者的偏好頻率，仍需更多實驗來進一步驗證。我們可以考慮加入反應時間等行為指標，作為補充依據，或設計更具挑戰性的實驗，例如讓受試者同時接受兩種或多種不同頻率的刺激，觀察模型認定的最適合頻率是否在這種情境下仍能優於其他頻率。透過這樣的實驗設計，我們將能更清楚地了解模型的準確性與可靠性。總結來說，未來研究的方向包括改進數據品質、擴充資料規模，以及設計更嚴謹的實驗來檢驗模型的穩定性與應用價值。

伍、 參考文獻

1. Lin, Z., Zhang, C., Wu, W., & Gao, X. (2007). Frequency recognition based on canonical correlation analysis for SSVEP-based BCIs. *IEEE transactions on bio-medical engineering*, 54(6 Pt 2), 1172–1176.
<https://doi.org/10.1109/tbme.2006.889197>
2. Chen, X., Wang, Y., Gao, S., Jung, T. P., & Gao, X. (2015). Filter bank canonical correlation analysis for implementing a high-speed SSVEP-based brain-computer interface. *Journal of neural engineering*, 12(4), 046008.
<https://doi.org/10.1088/1741-2560/12/4/046008>
3. I Nakanishi, M., Wang, Y., Chen, X., Wang, Y. T., Gao, X., & Jung, T. P. (2018). Enhancing Detection of SSVEPs for a High-Speed Brain Speller Using Task-Related Component Analysis. *IEEE transactions on bio-medical engineering*, 65(1), 104–112. <https://doi.org/10.1109/TBME.2017.2694818>